

Cost-sensitive logistička regresija na WDBC bazi: uticaj cene greške i grupa obeležja (oblik vs. veličina)

Teodora Todorović E9 2/2025

Apstrakt

U radu se logističkom regresijom (WDBC baza, $n=569$) klasifikuju tumori dojke kao maligni ili benigni. Umesto jedne podele podataka koristi se ponovljena unakrsna validacija (50 foldova) sa uparenim statističkim testovima. Testiraju se tri hipoteze: da li veća cena propuštenog malignog nalaza podiže osetljivost bez značajnog pada tačnosti (H1), da li obeležja oblika tumora bolje razdvajaju klase od obeležja veličine (H2), i da li model samo na obeležjima oblika drži korak sa modelom na svim obeležjima (H3). Osetljivost zaista raste sa cenom greške, ali bez statističke značajnosti, pa je H1 samo delimično potvrđena. Obeležja veličine nisu ništa lošija od obeležja oblika, često su čak i bolja, pa H2 nije potvrđena. Model treniran samo na obeležjima oblika statistički zaostaje za punim modelom, pa ni H3 nije potvrđena. Rezultati su upoređeni sa četiri objavljena rada na istoj bazi podataka.

1. Uvod

Rak dojke je jedno od najčešćih malignih oboljenja kod žena, pa rano i pouzdano razlikovanje malignih od benignih tumora direktno utiče na tok lečenja. Bazu Wisconsin Diagnostic Breast Cancer (WDBC) objavili su 1995. Wolberg, Mangasarian i Street. Sadrži 569 uzoraka opisanih sa 30 obeležja, izračunatih iz slike aspirata tanke igle (FNA) mase u dojci. Ovaj skup je decenijama standardni benchmark u ovoj oblasti, pa postoji mnogo objavljenih rezultata za poređenje.

Rad se oslanja na četiri istraživanja na istoj bazi:

Rad 1. Cheng i Yu (medRxiv, 2025) koriste logističku regresiju na jednoj 80/20 podeli i postižu tačnost 98,25% i AUC 0,9954. Sami priznaju da je to slaba tačka, jer bez unakrsne validacije ne znaju koliko je taj rezultat stabilan. Baš tu ovaj rad nastavlja dalje.

Rad 2. Sushma i Prasanna Kumar (The Imaging Science Journal, 2023) rešavaju sličan problem kao moj H1: standardna logistička regresija na WDBC bazi je pristrasna ka benignoj klasi, jer je ima više. Grid search-om pronalaze težine klasa u odnosu oko 14:1 u korist maligne klase i tvrde da cost-sensitive model postiže tačnost 99,99% naspram 94,73% za standardni model.

Rad 3. Bamodu (Cancer Informatics, 2026) ne trenira klasifikator, nego pravi ručno ponderisan dijagnostički skor od osam obeležja. Glavni rezultati (tačnost 92,6%, AUC 0,974) dobijeni su na celom skupu podataka, bez odvojenog test skupa. U radu se pominje i sekundarna 10-struka unakrsna validacija sa tačnošću 91,8%, koja je uporedivija sa mojim pristupom.

Rad 4. Raquib i dr. (arXiv, 2025) koriste SHAP analizu značaja obeležja na istoj bazi. Najuticajnije obeležje im je concave_points_worst (oblik), a odmah drugo area_worst (veličina). Ovo je direktno relevantno za moj H2.

Cilj rada je dvostruk: nadograditi Rad 1 rigoroznijom validacijom, i proveriti da li cena greške i izbor obeležja (oblik naspram veličine) stvarno utiču na performanse.

2. Podaci i metode

2.1 Skup podataka

WDBC baza ima 569 uzoraka, 357 benignih i 212 malignih, bez nedostajućih vrednosti i duplikata. Svaki uzorak opisuje 30 obeležja, po tri statistike (mean, se, worst) za deset osnovnih mera jezgra ćelije: radius, texture, perimeter, area, smoothness, compactness, concavity, concave_points, symmetry i fractal_dimension. Maligni tumor je kodiran kao pozitivna klasa ($y=1$), pa je osetljivost direktno klinička osetljivost.

Obeležja sam unapred podelila u tri grupe. SIZE: radius, perimeter, area, 9 obeležja. SHAPE: concavity, concave_points, compactness, 9 obeležja. OTHER: preostalih 12 obeležja.

2.2 Model i evaluacije

Koristim logističku regresiju sa L2 regularizacijom ($C=1,0$), unutar toka koji standardizaciju primenjuje samo na trening delu svakog folda, da bi se izbeglo curenje podataka. L2 je izabrana jer je WDBC, prema pratećoj dokumentaciji, linearno razdvojiva baza. Bez regularizacije bi koeficijenti mogli da porastu bez granice i model ne bi konvergirao. Cenu greške podešavam preko `class_weight`, gde je w cena propuštenog malignog nalaza u odnosu na lažni alarm.

Za sva poređenja koristim jednu fiksnu listu od 50 podela ($5 \text{ foldova} \times 10 \text{ ponavljanja}$), tako da su isti pacijenti u istim foldovima za svaki model. To omogućava upareno poređenje. Za značajnost razlika koristim Nadeau-Bengio korekciju, jer foldovi nisu potpuno nezavisni. Za pojedinačna obeležja (H_2) koristim bootstrap sa 1000 ponavljanja.

2.3 Napomena o uporedivosti sa literaturom


Rezultat Rada 1 (98,25%) dolazi iz jedne podele, bez unakrsne validacije. Glavni rezultat Rada 3 (92,6%) dolazi sa celog skupa podataka, bez test skupa. Moji rezultati dosledno dolaze iz 50 foldova unakrsne validacije. Zato razlike u tačnosti treba čitati oprezno, jer delom dolaze od razlike u strogosti evaluacije, ne samo od kvaliteta modela.

3. Rezultati

3.1 Baseline: jedna podela naspram unakrsne validacije

Na jednoj 80/20 podeli model postiže tačnost 0,9649, osetljivost 0,9286, specifičnost 0,9861 i AUC 0,9960 (matrica konfuzije: TP=39, FN=3, FP=1, TN=71). Ovo je blizu Radu 1, ali razlika od 3 naspram 1 propuštenog malignog nalaza, na istih 114 test uzoraka, pokazuje koliko jedna podela zavisi od slučajnog izbora.

Ponovim li istu proceduru na 100 slučajnih podela, srednja tačnost je $0,9761 \pm 0,0143$, sa rasponom od 0,9298 do 1,0000 (Slika 1). Skoro 7 procentnih poena razlike, na istim podacima, samo zbog izbora test skupa, dovoljno govori: jedna podela nije pouzdana mera.




Slika 1. Raspodela tačnosti modela na 100 različitih 80/20 podela istih podataka.

Sa 50 foldova unakrsne validacije dobijam stabilniju procenu: tačnost $0,9789 \pm 0,0143$, osetljivost $0,9576 \pm 0,0339$, specifičnost $0,9916 \pm 0,0089$, AUC $0,9948 \pm 0,0054$. Ovo je blizu proseku sa 100 podela, pa evaluacioni okvir radi kako treba.

3.2 H1: uticaj cene lažno negativnog nalaza

w	Osetljivost (M)	Specifičnost (B)	Tačnost	Trošak
1	$0,9576 \pm 0,0339$	$0,9916 \pm 0,0089$	$0,9789 \pm 0,0143$	$0,1634 \pm 0,1274$
2	$0,9656 \pm 0,0253$	$0,9742 \pm 0,0175$	$0,9710 \pm 0,0124$	$0,1444 \pm 0,0920$
5	$0,9707 \pm 0,0222$	$0,9521 \pm 0,0261$	$0,9591 \pm 0,0151$	$0,1390 \pm 0,0773$
10	$0,9717 \pm 0,0224$	$0,9260 \pm 0,0362$	$0,9431 \pm 0,0204$	$0,1518 \pm 0,0759$
20	$0,9736 \pm 0,0222$	$0,9047 \pm 0,0422$	$0,9304 \pm 0,0247$	$0,1581 \pm 0,0771$

Tabela 1. Metrike (srednja vrednost $\pm$ SD po 50 foldova) po cenama lažno negativnog nalaza (w), model na svih 30 obeležja.



Slika 2. Osetljivost i specifičnost u zavisnosti od w, sa error bar-ovima.

Porast osetljivost-a u odnosu na $w=1$ nije statistički značajan ni za jedno w . Svi intervali poverenja sadrže nulu, na primer za $w=10$: razlika $+0,0141$, $p=0,276$. Pad tačnosti, međutim, postaje značajan već od $w=5$ (razlika $-0,0199$, $p=0,046$), i raste sa w .


w	Δ tačnost	CI (95%)	Pad < 1 p.p.?
2	-0,0079	[-0,0187; 0,0029]	Ne
5	-0,0199	[-0,0394; -0,0004]	Ne
10	-0,0358	[-0,0624; -0,0093]	Ne
20	-0,0485	[-0,0793; -0,0177]	Ne

Tabela 2. Provera kriterijuma H1: donja granica intervala poverenja nijednom ne prelazi prag od $-0,01$.

Zaključak H1: hipoteza je delimično potvrđena. Smer je tačan, veće w daje viši osetljivost i nižu tačnost, ali ni porast osetljivost-a nije statistički značajan, niti je pad tačnosti pouzdano ispod 1 procentnog poena, čak ni za najblaže $w=2$.

3.3 H2: diskriminativna moć pojedinačnih obeležja

Za svako od 30 obeležja izračunala sam pojedinačni AUC sa bootstrap intervalom poverenja. Tri najviša AUC-a pripadaju SIZE grupi: perimeter_worst (0,9755), radius_worst (0,9704) i area_worst (0,9698). Odmah iza su dva SHAPE obeležja: concave_points_worst (0,9667) i concave_points_mean (0,9644).



Slika 3. AUC svih 30 obeležja, obojeno po grupi: SIZE (plavo), SHAPE (crveno), OTHER (sivo).


Obeležje	Grupa	AUC	95% CI
perimeter_worst	SIZE	0,9755	[0,9636; 0,9850]
radius_worst	SIZE	0,9704	[0,9572; 0,9813]
area_worst	SIZE	0,9698	[0,9559; 0,9809]
concave_points_worst	SHAPE	0,9667	[0,9504; 0,9801]
concave_points_mean	SHAPE	0,9644	[0,9493; 0,9767]
perimeter_mean	SIZE	0,9469	[0,9267; 0,9630]
area_mean	SIZE	0,9383	[0,9165; 0,9563]
concavity_mean	SHAPE	0,9378	[0,9180; 0,9570]
radius_mean	SIZE	0,9375	[0,9155; 0,9554]
compactness_worst	SHAPE	0,8623	[0,8316; 0,8912]

Tabela 3. Deset obeležja sa najvišim AUC-om (svih 30 u pratećem CSV fajlu).

Uparena poređenja SHAPE naspram SIZE, po istoj verziji (mean, se, worst), daju jasniji odgovor: SHAPE nije bolji ni u jednom od 9 poređenja, dok je SIZE bolji u 6 od 9 (Tabela 4).

SHAPE obeležje	SIZE obeležje	Δ AUC (SHAPE–SIZE)	95% CI	SIZE bolji?
concave_points_mean	perimeter_mean	+0,0175	[-0,0010; 0,0384]	Ne
concave_points_se	perimeter_se	-0,0846	[-0,1155; -0,0536]	Da
concave_points_worst	perimeter_worst	-0,0087	[-0,0234; 0,0060]	Ne
concavity_mean	area_mean	-0,0005	[-0,0265; 0,0281]	Ne
concavity_se	area_se	-0,1456	[-0,1844; -0,1097]	Da
concavity_worst	area_worst	-0,0485	[-0,0721; -0,0237]	Da
compactness_mean	radius_mean	-0,0737	[-0,1077; -0,0361]	Da
compactness_se	radius_se	-0,1411	[-0,1867; -0,0979]	Da
compactness_worst	radius_worst	-0,1081	[-0,1391; -0,0763]	Da

Tabela 4. Uparena poređenja AUC-a devet parova SHAPE/SIZE obeležja (bootstrap, 1000 ponavljanja).



Slika 4. Korelacije SIZE i SHAPE obeležja. Gornji levi kvadrat (SIZE) pokazuje jaku kolinearnost ($|r| = 0,8492$), donji desni (SHAPE) slabiju ($|r| = 0,7046$).

Zaključak H2: hipoteza nije potvrđena. Obeležja veličine, posebno worst i se verzije, jednako su dobra ili bolja od obeležja oblika u većini poređenja. Analiza je eksplorativna, pokriva 9 od mogućih 45 parova, ne sve kombinacije.


3.4 H3: SIZE naspram SHAPE naspram svih obeležja

Grupa	w	Osetljivost	Specifičnost	Tačnost	AUC	Trošak	Os. Na spec. 95%
ALL	1	0,9576	0,9916	0,9789	0,9948	0,1634	0,9726
ALL	10	0,9717	0,9260	0,9431	0,9902	0,1518	0,9674
SHAPE	1	0,8811	0,9605	0,9309	0,9774	0,4678	0,9066
SHAPE	10	0,9627	0,8039	0,8631	0,9769	0,2620	0,9037
SIZE	1	0,8750	0,9610	0,9290	0,9817	0,4901	0,8944
SIZE	10	0,9712	0,8238	0,8787	0,9842	0,2178	0,9084

Tabela 5. Rezultati po grupama obeležja i po w (srednje vrednosti po 50 foldova).

Pri $w=10$, SHAPE je statistički lošiji od ALL i za osetljivost pri specifičnosti 95% (razlika $-0,0637$, $p=0,022$) i za trošak (razlika $+0,1102$, $p=0,041$). SHAPE i SIZE se međusobno ne razlikuju značajno ni za jednu od te dve metrike.

Test neinferiornosti (SHAPE naspram ALL, margina 1 procentni poen) je odbačen: donja granica intervala poverenja ($-0,1180$) daleko je ispod praga od $-0,01$. SHAPE grupa nije ekvivalentna korišćenju svih 30 obeležja.



Slika 5. Usrednjene ROC krive (50 foldova) za tri grupe obeležja pri $w=10$.

Zaključak H3: hipoteza nije potvrđena ni u jednom delu. SHAPE je lošiji od punog modela, a nije bolji od SIZE.

4. Diskusija

Rezultati dosledno pokazuju da smanjenje broja obeležja, na SIZE ili na SHAPE, pogoršava performanse u odnosu na svih 30 obeležja. SHAPE grupa nema prednost nad SIZE, suprotno polaznoj ideji da bi nepravilnosti u obliku jezgra mogle biti diskriminativnije od same veličine. To se slaže i sa Radom 1, gde su među deset najuticajnijih obeležja i mere veličine i mere oblika. Oba tipa obeležja očigledno nose komplementarnu informaciju.

Moj CV-zasnovan rezultat (0,9789 na svih 30 obeležja) je blizu tačke procene iz Rada 1 (0,9825), ali sa dodatom merom neizvesnosti koju njihova jedna podela nije mogla da pruži. Baš to oni sami navode kao slabost svog rada, i Slika 1 pokazuje zašto: njihov rezultat je mogao lako da padne u raspon od preko 6 procentnih poena, samo zbog izbora podele.

Poređenje sa Radom 2 je zanimljivo jer koriste istu bazu i isti test skup (114 uzoraka, 42 maligna i 72 benigna) kao moja jedna podela. To nije slučajnost, nego matematička posledica iste stratifikovane podele iste baze. Njihova optimalna težina klasa (odnos oko 14:1) po redu veličine odgovara mom najvišem testiranom $w=20$. Njihov rezultat, tačnost 99,99% naspram 94,73%, mnogo je izraženiji efekat nego što sam ja videla za H1.

Pažljivijim čitanjem njihovog rada, ipak, uočavaju se problemi. Matrica konfuzije pokazuje samo 1 grešku od 114 uzoraka (tačnost 99,12%), tekst na drugom mestu kaže 112 od 114 tačno (98,25%), a zaključak pominje treći broj, 99,99%, bez objašnjenja da li je reč o istom test skupu. Nikakva mera neizvesnosti nije prijavljena. Ovo ne umanjuje njihov metodološki doprinos, pristup grid search-om

je legitiman, ali dobro pokazuje zašto su upareni statistički testovi sa intervalima poverenja bitni: bez njih i nekonzistentni rezultati mogu delovati ubedljivo.

Rad 3 ide drugim putem, ručno ponderisan skor umesto klasifikatora, sa naglaskom na interpretabilnost. Njihova tačnost (92,6%) je niža od moje, ali je dobijena bez odvojenog test skupa. Njihova sekundarna 10-struka CV (91,8%) je uporedivija, i bliža je mojim SHAPE/SIZE rezultatima nego punom modelu. Zanimljivo je da i njihova fold-change analiza rangira concavity i concave_points najviše, slično kao moj H2, ali moja AUC analiza pokazuje da to ne prevodi nužno u bolji AUC od SIZE obeležja. Fold-change i AUC očigledno mere različite stvari.

Rad 4 (PSO-XAI) potvrđuje isti obrazac drugom metodom. Njihova SHAP analiza stavlja concave_points_worst na prvo mesto, a area_worst odmah iza. Skoro identično mom rangiranju, gde su ta ista obeležja pri vrhu, izmešana. Dve nezavisne analize, na različitim metodama i različitom kodu, dolaze do istog zaključka da nijedna grupa obeležja jasno ne dominira.

5. Ograničenja

Starost baze. WDBC je iz ranih 1990-ih, sa jezgrima segmentiranim ručno ili poluautomatski, što ograničava prenosivost na savremene digitalne slike.

Nema spoljne validacije. Svi rezultati, uključujući sva četiri poređena rada, potiču iz iste baze. Nema nezavisne kohorte za proveru.

Fiksiran hiperparametar. $C=1,0$ nije podešavan unutar unakrsne validacije, što je pojednostavljeno.

Foldovi nisu nezavisni. Dele preklapajuće trening podskupove. Nadeau-Bengio korekcija to ublažava, ali ne otklanja potpuno.

H2 analiza je eksplorativna. Pokriva 9 od mogućih 45 parova obeležja, odabranih prema uputstvu zadatka, ne iscrpnom pretragom.

Ograničena uporedivost sa literaturom. Kao što je rečeno u 2.3, brojevi iz Rada 1 i glavni brojevi iz Rada 3 ne dolaze iz iste vrste evaluacije kao moji. Razlike u tačnosti su delom razlike u strogosti protokola, ne samo u kvalitetu modela.

6. Zaključak

Hipoteza	Status	Ključni nalaz
H1	Delimično podržana	Osetljivost raste sa w (0,9576→0,9736), ali bez statističke značajnosti; pad tačnosti < 1 p.p. nije potvrđen ni za jedno w .
H2	Nije podržana	SHAPE nije značajno bolji od SIZE ni u jednom od 9 poređenja; SIZE je značajno bolji u 6/9 parova.
H3	Nije podržana	SHAPE je značajno lošiji od ALL (test neinferiornosti odbačen); SHAPE i SIZE se međusobno ne razlikuju.

Tabela 6. Zbirni pregled ishoda hipoteza.

Ponovljena unakrsna validacija pokazuje da je procena performansi na WDBC bazi mnogo pouzdanija kada se ne oslanja na jednu podelu. Razlika od preko 6 procentnih poena između slučajnih

podela (Slika 1) to jasno govori. Nijedna hipoteza o superiornosti obeležja oblika (H2, H3) nije potvrđena, obeležja veličine su jednako dobra ili bolja.

Literatura

- [1] Cheng, W., & Yu, Z. (2025). A Fast and Interpretable Logistic Regression Framework for Breast Tumor Classification Using the Wisconsin Diagnostic Dataset. medRxiv preprint. <https://www.medrxiv.org/content/10.64898/2025.12.23.25342946.full.pdf>
- [2] Sushma, S. J., & Prasanna Kumar, S. C. (2023). A cost-sensitive logistic regression model for breast cancer detection. The Imaging Science Journal, 71(2). <https://doi.org/10.1080/13682199.2022.2161697>
- [3] Bamodu, O. A. (2026). Contextualized Malignantization: Morphometric Signatures of Breast Tissue Transformation and a Clinically Translatable Diagnostic Algorithm. Cancer Informatics, 25. <https://pmc.ncbi.nlm.nih.gov/articles/PMC13451761/>
- [4] Raquib, M., Das, N., Prity, F. S., Al Fahim, A., Murad, S. A., Hossain, M. A., Hoque, M. J., & Moni, M. A. (2025). PSO-XAI: A PSO-Enhanced Explainable AI Framework for Reliable Breast Cancer Detection. arXiv:2510.20611. <https://arxiv.org/abs/2510.20611>
- [5] Wolberg, W., Mangasarian, O., Street, N., & Street, W. (1995). Breast Cancer Wisconsin (Diagnostic) [Dataset]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5DW2B>